

1. Extract:

Utilizando Selenium e Javascript, foi extraído dados do site “<https://books.toscrape.com/>” de forma automatizada com um looping de click, conseguindo consumir todas as páginas utilizando o arquivo scrapy.py.

Após essa extração, faz outro Scraping para dar update na tabela com categorias e avaliação dos livros. Utiliza-se o arquivo scrapy2.py.

2. Load:

Após a extração total dos dados, foi criado um banco chamado “livraria.db” no próprio Python em SQLite3 para o carregamento bruto dos dados com a seguinte padronização:

```
query = """
```

```
CREATE TABLE IF NOT EXISTS livros(  
    id INTEGER PRIMARY KEY AUTOINCREMENT,  
    titulo TEXT NOT NULL,  
    preco REAL,  
    disponibilidade TEXT,  
    categoria TEXT,  
    avaliacao REAL,  
    data_extracao TIMESTAMP DEFAULT CURRENT_TIMESTAMP  
);
```

```
"""
```

3. Transform:


Com os dados carregados, houve a consumação do banco de dados “livraria.db” para o tratamento robusto. Percebendo que os dados brutos poderiam ter livros duplicados, espaços em branco e valores nulo em float, que não é interessante para fazer a análise com contas, utilizei os métodos a seguir:

Para a coluna preço, foi feito um replace para remover símbolos gerando apenas um numero, transformando-os para float e se tiver algum nulo, deixar como 0, para a coluna texto apenas foi removido os espaços em branco e para a coluna avaliação foi transformado ela para int e colocando como 0 todos os nulos.

4. Análise

No total foram gerados 5 Gráficos para responder as 5 perguntas mais necessárias para esse grupo de dados.

1.Existem livros com 0 de estoque?



Resposta: Com base no dado gerado, a resposta é que não existem livros sem estoque.

2. Quero saber como a base de dados está completa, para visualizar o banco de uma forma mais fácil.

Resumo de Livros Coletados (Top 20)					
id	titulo	preco	disponibilidade	categoria	avaliacao
1	A Light in the Attic	51.77	in stock	Poetry	3
2	Tipping the Velvet	53.74	in stock	Historical Fiction	1
3	Soumission	50.1	in stock	Fiction	1
4	Sharp Objects	47.82	in stock	Mystery	4
5	Sapiens: A Brief History of ...	54.23	in stock	History	5
6	The Pequoten Reed	22.65	in stock	Young Adult	1
7	The Dirty Little Secrets of ...	33.34	in stock	Business	4
8	The Coming Woman: A Novel Ba...	17.93	in stock	Default	3
9	The Boys in the Boat: Nine A...	22.6	in stock	Default	4
10	The Black Maria	52.15	in stock	Poetry	1
11	Starving Hearts Triangular ...	13.99	in stock	Default	2
12	Shakespeare's Sonnets	20.66	in stock	Poetry	4
13	Set Me Free	17.46	in stock	Young Adult	5
14	Scott Pilgrim's Precious Li...	52.29	in stock	Sequential Art	5
15	Rip It Up and Start Again	35.02	in stock	Music	5
16	Our Band Could Be Your Life!...	57.25	in stock	Music	3
17	Olio	23.88	in stock	Poetry	1
18	Mesaerion: The Best Science ...	37.59	in stock	Science Fiction	1
19	Libertarianism for Beginners	51.33	in stock	Politics	2
20	It's Only the Himalayas	45.17	in stock	Travel	2

3. Quais categorias tem mais quantidade de livros?

Top 15 Categorias com Mais Livros

Categoria	Qtd de Livros
Default	152
Nonfiction	110
Sequential Art	75
Add a comment	67
Fiction	65
Young Adult	54
Fantasy	47
Romance	35
Mystery	32
Food and Drink	30
Childrens	29
Historical Fiction	26
Poetry	19
Classics	19
History	18

Resposta: Com base na tabela criada, Default, nonfiction e sequential art são as categorias com mais livros na livraria.


4. quantos livros tem para cada nota de avaliação, ou seja, os livros estão com a avaliações positivas ou negativas?

Quantidade de Livros por Avaliação

Estrelas	Qtd de Livros
5 Estrela(s)	195
4 Estrela(s)	179
3 Estrela(s)	203
2 Estrela(s)	196
1 Estrela(s)	226

Reposta: Com base na tabela gerada, e colocando como regra de negócio, que livros com 5 e 4 estrelas são positivos, livros com 3 estrelas são neutros e livros com 1 e 2 estrelas são negativos. A tabela nos mostra que existem 374 livros com avaliações positivas e 422 livros com avaliações negativas, tendo mais negativas.

5.Com as informações anteriores, vem uma pergunta, qual a média de preço dos livros avaliados?



Resposta: O gráfico mostra que os livros que tem 4 estrelas tem a média de valor mais alta, ou seja, os livros mais caros são os melhores avaliados.

5.Conclusões e dificuldades:

O projeto teve um andamento linear, com utilizações das bibliotecas que estão no requirements.txt, sem dificuldades em utilizar as bibliotecas, porém tive dificuldade em gerar insights por ter um banco de dados muito pobre. Tendo então, ter que criar mais um Scrapy e depois fazer um update no banco com mais consumação de mais dados. Outra dificuldade foi gerenciar o tamanho da tabela, com isso , tive que colocar uma média de 10 a 15 linhas na visualização da tabela.